HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN 1

Sales Copilot: Xây dựng Trợ lý AI Tư vấn Sản phẩm bằng Multi-source RAG và Agentic AI

Giảng viên hướng dẫn : Kim Ngọc Bách

Họ và tên sinh viên : Phan Anh Minh Đức

Mã sinh viên : B23DCCE022

Lớp : D23CQCE04-B

Học phần : Thực tập cơ sở

Hà Nội-2025

1. Giới thiệu dự án

1.1. Lý do chọn đề tài

Trong bối cảnh kỷ nguyên thương mại điện tử và mô hình phân phối đa kênh (Omnichannel) đang chứng kiến sự bùng nổ theo cấp số nhân, hệ thống danh mục sản phẩm cùng các quy chuẩn bán hàng liên tục chịu sự biến đổi không ngừng. Căn cứ vào hiện thực khách quan, hoạt động vận hành của các thực thể doanh nghiệp đang vướng mắc tại những điểm tồn tại mang tính hệ thống như sau:

- **Sự quá tải của đội ngũ nhân sự chuyên trách:** Lực lượng tư vấn viên bị đặt dưới áp lực phải ghi nhớ và truy xuất khối lượng khổng lồ các mã định danh sản phẩm (SKU), cấu hình kỹ thuật đặc thù, những chính sách bảo hành chồng chéo phức tạp, cũng như các kịch bản biện luận nhằm xử lý sự từ chối từ phía khách hàng (Objection Handling). Việc não bộ con người phải xử lý hàng vạn biến số dữ liệu trong thời gian thực dẫn đến sự suy giảm tất yếu về mặt hiệu suất. Trạng thái này được xem là nguyên nhân cốt lõi dẫn đến các sai lệch trong quá trình tư vấn, làm sụt giảm uy tín thương hiệu và làm gia tăng đáng kể chi phí đào tạo nghiệp vụ đối với nhân sự mới.
- **Những giới hạn cốt lõi của phương thức tìm kiếm truyền thống (Lexical Search):** Các chủ thể tiêu dùng có xu hướng thực thi các truy vấn bằng ngôn ngữ tự nhiên, ngôn ngữ địa phương hoặc sử dụng các hệ thống từ khóa thiếu tính chuẩn xác về mặt kỹ thuật. Các công cụ tìm kiếm dựa trên đối sánh chuỗi ký tự tĩnh (Exact Match/Keyword-based) thiếu vắng năng lực nội suy để hiểu được các cấu trúc đồng nghĩa hoặc sự sai lệch chính tả. Do đó, chúng thường xuyên thất bại trong việc trả về kết quả tương thích, qua đó trực tiếp làm suy giảm tỷ lệ chuyển đổi thương mại (Conversion Rate) và gây ra tình trạng thất thoát giao dịch ngay tại điểm chạm đầu tiên.

Nhằm mục đích giải quyết một cách triệt để các bất cập nêu trên, đề tài nghiên cứu **"Sales Copilot"** được đề xuất như một nỗ lực kiến tạo một hệ thống Trí tuệ nhân tạo (AI) sở hữu năng lực phân tích ngữ nghĩa truy vấn đa chiều, tiến hành truy xuất dữ liệu với độ chính xác cao và tự động hóa quá trình tổng hợp các phản hồi tư vấn mang tính chuyên môn sâu.

1.2. Ý nghĩa

Ý nghĩa cốt lõi của dự án nằm ở việc chuyển dịch mô hình vận hành từ nhân lực thủ công sang hỗ trợ bởi trí tuệ nhân tạo chuyên sâu, tạo ra một bệ phóng tri thức vững chắc cho doanh nghiệp. Dự án không nhằm mục đích thay thế con người, mà mang ý nghĩa kiến tạo một trợ lý thông minh (Copilot) song hành cùng nhân sự. Hệ thống này giải phóng đội ngũ bán hàng khỏi các tác vụ tra cứu thông tin lặp đi lặp lại mang tính máy móc, từ đó cho phép họ tập trung toàn bộ năng lực trí tuệ và cảm xúc vào nghệ thuật đàm phán, thấu hiểu tâm lý khách hàng và thiết lập các mối quan hệ thương mại bền vững.

1.3. Tính ứng dụng

Công trình nghiên cứu này được xác định là sẽ thiết lập những giá trị thực tiễn mang tính chiến lược, tạo ra lợi thế cạnh tranh với tính ứng dụng cao trong các môi trường doanh nghiệp quy mô lớn:

- **Tối ưu hóa nguồn lực và thời gian hội nhập:** Ứng dụng trong nội bộ doanh nghiệp giúp tiết giảm tối đa thời lượng cần thiết cho công tác hội nhập và đào tạo đối với nhân sự mới (giảm từ đơn vị tháng xuống đơn vị tuần).
- **Mở rộng năng lực phục vụ (Scalability):** Ứng dụng trực tiếp vào các nền tảng thương mại điện tử giúp xử lý lưu lượng truy cập khách hàng tăng đột biến trong các sự kiện siêu khuyến mãi, giải quyết triệt để nút thắt cổ chai về thiếu hụt nhân sự trực tuyến.
- **Hỗ trợ đa nền tảng:** Hệ thống có thể được tích hợp liền mạch thông qua API vào các hệ thống Quản trị Quan hệ Khách hàng (CRM) hiện hữu, các nền tảng tổng đài nội bộ hoặc triển khai dưới dạng chatbot trực tiếp trên website (B2C).

1.4. Giá trị học thuật

Xét trên phương diện nghiên cứu khoa học máy tính và phát triển hệ thống phần mềm, công trình này được kỳ vọng sẽ mang lại những đóng góp nền tảng bao gồm:

- **Làm chủ và cải tiến kiến trúc Advanced RAG:** Việc áp dụng các kỹ thuật xử lý và đồng hóa dữ liệu tiên tiến được thực hiện nhằm mục đích vượt qua những giới hạn cố hữu của mô hình RAG sơ khởi (Naive RAG) - một mô hình thường xuyên gặp rủi ro trong việc trích xuất các thông tin rời rạc và đánh mất bối cảnh tổng thể của văn bản gốc.
- **Thiết lập Không gian Vector Đa phương thức và Đa cấu trúc (Multi-source Vector Space):** Đề xuất một phương pháp luận nhằm giải quyết bài toán cực kỳ phức tạp về mặt kỹ

thuật trong việc dung hợp dữ liệu có cấu trúc định lượng (CSV) và dữ liệu phi cấu trúc định tính (PDF/TXT) vào chung một không gian truy xuất toán học duy nhất, đảm bảo khả năng tính toán độ tương đồng một cách công bằng giữa các loại hình dữ liệu.

- **Phát triển Hệ thống Trí tuệ Nhân tạo Đại lý (Agentic AI):** Thực hiện bước chuyển dịch mô hình căn bản từ các hệ thống truy vấn thụ động sang kiến trúc AI đại lý (Agent) sở hữu năng lực tự thân suy luận (Reasoning), lập kế hoạch (Planning) và kích hoạt các công cụ ngoại vi (Tool Calling).

2. Cơ sở lý thuyết và công nghệ sử dụng

2.1. Các mô hình mgôn ngữ lớn (LLMs) và Những giới hạn hiện tại

Mặc dù các mô hình ngôn ngữ lớn đã minh chứng được năng lực xử lý ngôn ngữ tự nhiên một cách xuất sắc thông qua attention mechanisms, việc triển khai các mô hình này vào các hệ sinh thái doanh nghiệp thường làm bộc lộ ba điểm hạn chế mang tính đặc thù nội tại:

- **Hiện tượng Ảo giác (Hallucination):** Đây là khuynh hướng của mô hình trong việc tự động kiến tạo ra các thông tin phi thực tế với độ tự tin cao. Do bản chất của LLM là các cỗ máy dự đoán xác suất chuỗi ký tự dựa trên phân phối dữ liệu huấn luyện, chúng không sở hữu các cơ chế xác thực tính sự thật nội tại. Hậu quả là, việc mô hình đưa ra các mức giá không có thực hoặc các chính sách bảo hành vượt quá quy định là một rủi ro mang tính hiện hữu, có khả năng dẫn đến các tranh chấp pháp lý nghiêm trọng [3].
- **Giới hạn cửa sổ ngữ cảnh (Context Window Limit):** Việc nhúng toàn bộ cơ sở dữ liệu sản phẩm khổng lồ vào câu lệnh mồi trong mỗi chu kỳ truy vấn vẫn được xem là một rào cản bất khả thi. Nguyên nhân bắt nguồn từ độ phức tạp tính toán bậc hai của cơ chế self-attention truyền thống, gây tiêu hao nguồn lực tính toán khổng lồ.
- **Tình trạng trễ hạn dữ liệu (Data Staleness):** Khối lượng tri thức của các LLM bị phong tỏa tại thời điểm kết thúc quá trình huấn luyện. Quá trình tái tinh chỉnh (Fine-tuning) để cập nhật tri thức không thể đáp ứng được tần suất cập nhật theo thời gian thực.

Giải pháp sinh văn bản được Tăng cường truy xuất (Retrieval-Augmented Generation - RAG), được đề xuất bởi Lewis và cộng sự [5], được nhận định là cơ chế ưu việt nhằm khắc phục các nhược điểm nêu trên thông qua sự kết hợp giữa năng lực sinh ngữ cảnh của LLM và các kho lưu trữ tri thức ngoại vi.

2.2. Kiến trúc Advanced RAG và sự cải tiến so với Naive RAG

Nghiên cứu này triển khai kiến trúc **Advanced RAG** thông qua việc tích hợp các phương pháp luận cải tiến sâu rộng nhằm quản trị dữ liệu ở độ hạt vi mô.

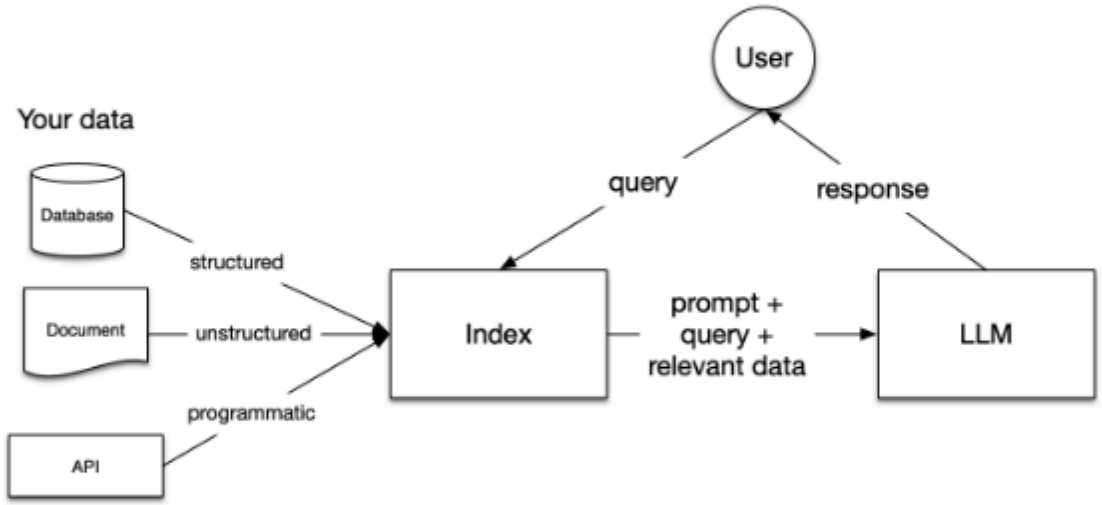

2.2.1. Tiến trình tiếp nhận và đồng hóa dữ liệu phức hợp

Việc trích xuất dữ liệu từ các định dạng tệp PDF theo phương thức phân tích chuỗi văn bản thuần túy thường gây ra sự phá vỡ cấu trúc mang tính quy chuẩn của các bảng biểu (Tables). Dự án hiện tại ứng dụng LlamaParse, một công cụ phân tích cú pháp vận hành dựa trên nền tảng thị giác máy tính quy mô lớn (Vision-Language Models). Kỹ thuật này tiếp cận các trang tài liệu dưới dạng đồ họa hai chiều, sử dụng AI để phân định các vùng bao (bounding boxes) của bảng biểu, qua đó bảo toàn nguyên vẹn sự tương quan dòng/cột thông qua việc tái cấu trúc chúng dưới định dạng Markdown tiêu chuẩn trước khi chuyển tiếp vào quy trình nhúng.

2.2.2. Phân mảnh theo ngữ nghĩa (Semantic Chunking) và phân mảnh phân cấp

Thay vì thực hiện phân mảnh tài liệu thông qua cơ chế đếm token tuyến tính, hệ thống được thiết kế để áp dụng các thuật toán phân mảnh thích ứng:

- **Phân mảnh theo ngữ nghĩa (Semantic Chunking):** Tiến hành phân tách tài liệu dựa trên

các ranh giới biến thiên về mặt ý nghĩa (Semantic boundaries). Quá trình này định lượng khoảng cách Cosine giữa các mệnh đề kề cận. Khi biên độ dao động vượt ngưỡng thiết lập, lệnh phân tách được kích hoạt.

- **Phân mảnh phân cấp (Hierarchical Chunking / Parent-Child Retrieval):** Phương pháp luận này phân chia tài liệu thành các khối cấu trúc thượng tầng và hạ tầng. Hệ thống thực hiện nhúng toán học và tìm kiếm trên khối hạ tầng nhằm tối ưu hóa độ chuẩn xác; song, khi kết quả được xác định, toàn bộ khối thượng tầng bao trùm sẽ được truy xuất và cung cấp cho LLM nhằm duy trì tính toàn vẹn bối cảnh [2].

2.3. Chiến lược truy xuất lai (Hybrid Search) và tái xếp hạng (Re-ranking)

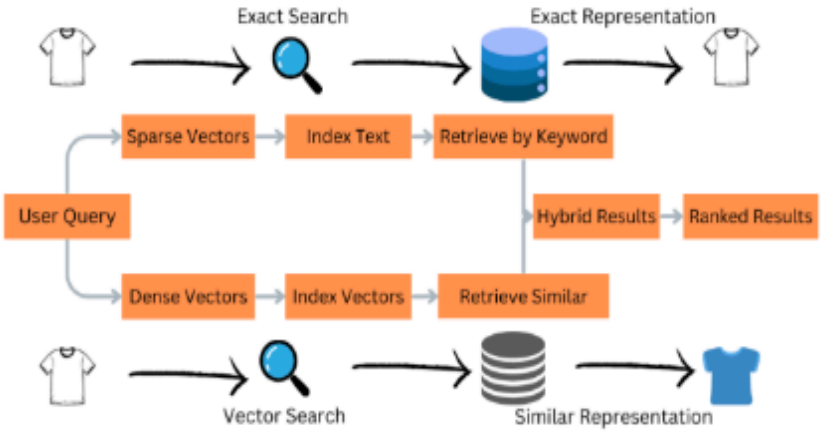

Nhằm mục đích tối ưu hóa tiến trình truy xuất dữ liệu trong một hệ sinh thái thông tin hàm chứa nhiều mức độ nhiễu loạn, một phương thức kết hợp song hành giữa hai trường phái truy xuất đối lập nhưng tương hỗ đã được thiết lập:

1. **Truy xuất mật độ cao (Dense Retrieval):** Vận dụng kỹ thuật Vector Embedding nhằm chuyển hóa nội hàm ngữ nghĩa truy vấn thành biểu diễn không gian n-chiều đa hướng. Phương pháp này tích hợp với cấu trúc dữ liệu đồ thị HNSW (Hierarchical Navigable Small World) để thực thi các thuật toán xấp xỉ khoảng cách, dò tìm các thực thể mang đặc tính tương đồng về mặt nội dung bất chấp sự sai khác từ vựng học [4].
2. **Truy xuất mật độ thấp (Sparse Retrieval):** Vận dụng thuật toán BM25 vận hành dựa trên mô hình định lượng Tần suất Thuật ngữ - Tần suất Tài liệu Nghịch đảo (TF-IDF). Hệ thống

này đánh giá sự trùng khớp chính xác của các ký tự cấu thành, một thiết chế đặc biệt trọng yếu nhằm bắt giữ nguyên vẹn các định danh sản phẩm (SKU) có cấu trúc mã hóa phức tạp [7].

Tái xếp hạng thông qua Cross-Encoder (Cross-Encoder Re-ranking): Tập hợp kết quả khởi thủy từ cơ chế Hybrid Search sẽ được định tuyến qua mô hình AI thứ cấp. Cross-Encoder tiến hành ghép nối trực tiếp [Câu truy vấn gốc] và [Từng thực thể tài liệu] vào cùng một đường ống Transformer. Sự tương tác tự chú ý (Self-attention) chéo cho phép phân tích sự tương quan với độ chi tiết tối đa, từ đó thiết lập điểm số phân loại mang tính chung thẩm. Kỹ thuật này được chứng minh là giúp gia tăng Độ chính xác truy xuất lên mức tiệm cận tối đa [6].

2.4. Hệ thống Trí tuệ nhân tạo đại lý (Agentic RAG)

Điểm đột phá mang tính cách mạng về mặt kiến trúc của dự án nằm ở việc ứng dụng Agentic AI thông qua bộ khung phương pháp luận ReAct (Reasoning + Acting) [8]. Agent được thiết kế để tự động kích hoạt tiến trình suy luận vòng lặp (Loop Reasoning) thông qua cơ chế Gọi Công cụ (Tool Calling). Tiến trình này tuân thủ chuỗi logic nội tại: Suy nghĩ (Thought) -> Hành động (Action) -> Quan sát (Observation). Quá trình này cho phép hệ thống sở hữu năng lực xử lý các truy vấn ngoại biên và khả năng tự phục hồi lỗi khi một công cụ thất bại.

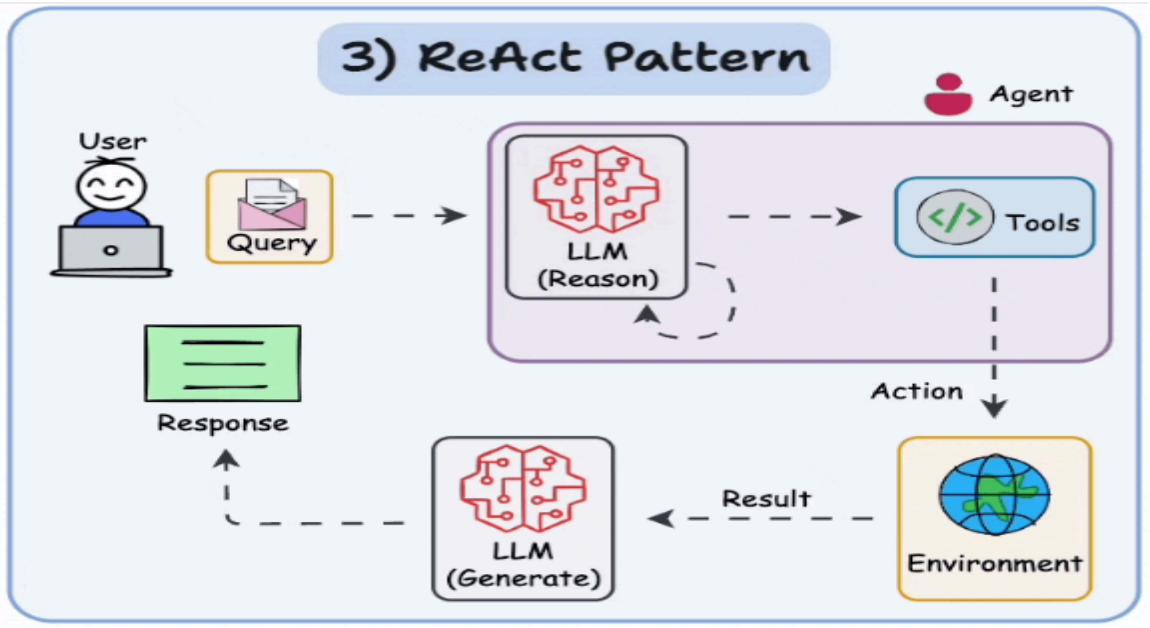

2.5. Công tác Kiểm định và đánh giá hệ thống (Evaluation)

Dự án ứng dụng bộ khung tiên tiến **RAGAS (Retrieval Augmented Generation Assessment)**, sử dụng cơ chế LLM đóng vai trò là Giám khảo (LLM-as-a-judge) [1] để đánh giá hệ thống thông qua các chỉ số:

- **Context Precision & Recall:** Đánh giá khả năng và mức độ toàn diện của hệ thống truy xuất.
- **Faithfulness:** Đảm bảo tính ràng buộc tuyệt đối của các hệ quả đầu ra, loại trừ ảo giác thông tin.
- **Answer Relevance:** Đánh giá mức độ giải quyết trực tiếp các trọng tâm của truy vấn khởi thủy.

3. Phân tích yêu cầu của dự án

3.1. Các yêu cầu mang tính chức năng (Functional Requirements)

- **Tiếp nhận và đồng bộ dữ liệu đa định dạng (Multi-format Data Ingestion & Sync):** Năng lực tự động đọc, tiền xử lý, bóc tách và tạo chỉ mục từ các định dạng tệp CSV (tệp danh mục) và PDF/TXT (tài liệu bảng biểu, chính sách). Phải tích hợp cơ chế cập nhật gia tăng (Incremental updates).
- **Đường ống Truy xuất lai (Hybrid Search Pipeline):** Khả năng thực thi đồng bộ hai thuật toán Vector Search và BM25, nối tiếp bằng quy trình Re-ranking nhằm xuất ra chuỗi kết quả có độ tin cậy cao nhất.
- **Năng lực suy luận và điều phối công cụ (Agentic Reasoning):** Khả năng nhận diện chính xác đa ý đồ truy vấn trong một câu lệnh phức hợp nhằm phân tách tác vụ, điều hướng và kích hoạt các chuỗi công cụ tuần tự hoặc song song.
- **Kiến tạo phản hồi nghiệp vụ đa bối cảnh:** Khả năng nhận diện cảm xúc ẩn dưới truy vấn của khách hàng nhằm vận dụng các kịch bản xử lý phản biện mang sắc thái tương thích.
- **Giao diện tương tác (Chat UI):** Thiết lập giao diện người dùng trực quan, đi kèm với cơ chế lưu trữ bộ nhớ hội thoại dài hạn (Long-term Chat Memory) và khả năng xử lý đại từ nhân xưng (Coreference Resolution).

3.2. Các Yêu cầu Phi chức năng (Non-functional Requirements)

- **Độ trễ phản hồi định mức (Latency Constraints):** Đảm bảo thời lượng khởi tạo Token đầu tiên (Time to First Token - TTFT) phải duy trì ở ngưỡng dưới 1.5 giây, và tổng thời gian hoàn tất chuỗi suy luận nội bộ không vượt quá 5.0 giây thông qua kỹ thuật Streaming.
- **Độ chuẩn xác tuyệt đối (Accuracy) và Kháng Ảo giác:** Duy trì chỉ số Faithfulness tĩnh > 0.95 trên tập kiểm nghiệm. Tuyệt đối không được cấp quyền tự điều chỉnh thông số định giá, quy định đổi trả.
- **Khả năng mở rộng quy mô tuyến tính (Linear Scalability):** Cơ sở Dữ liệu Vector phải duy trì trạng thái vận hành ổn định trong tình huống lưu lượng truy cập đồng thời đạt ngưỡng đỉnh điểm với hàng triệu vector.
- **Tiêu chuẩn bảo mật thông tin (Security):** Thiết lập các lớp lá chắn từ vựng (System Prompts) nhằm vô hiệu hóa các phương thức tấn công tiêm nhiễm câu lệnh (Prompt Injection), thiết lập cơ chế kiểm soát truy cập phân quyền.

4. Kế hoạch thực hiện dự án

Quá trình triển khai dự án được quy hoạch thực thi dựa trên phương pháp luận quản trị dự án linh hoạt Agile/Scrum, với chu kỳ phát triển kéo dài 8 tuần .

Tuần	**Giai đoạn & Trọng tâm thực thi kỹ thuật**	**Đầu ra dự kiến (Deliverables)**
Tuần 1	**Nghiên cứu, Phân tích:** - Tổng hợp cơ sở tài liệu, phác thảo luồng tương tác (Data flow). - Phân tích hiệu suất LLM	Hồ sơ đặc tả hệ thống và sơ đồ kiến trúc tổng thể.

	và Embedding Model chuyên biệt.	
Tuần 2	**Thu thập, trích xuất dữ liệu cơ sở:** - Tổng hợp kho dữ liệu thực nghiệm (CSV danh mục, PDF nghiệp vụ). - Khử nhiễu, chuẩn hóa định dạng (UTF-8), ẩn danh hóa dữ liệu nhạy cảm.	Tập dữ liệu tiêu chuẩn (Clean Ground-truth Dataset).
Tuần 3	**Kiến tạo đường ống xử lý dữ liệu:** - Tinh chỉnh tham số LlamaParse bóc tách bảng biểu. - Triển khai thuật toán Semantic Chunking và Hierarchical Parsing.	Đường ống tiếp nhận dữ liệu (Ingestion Pipeline) tự động hóa.
Tuần 4	**Triển khai Vector DB và Hybrid Search:** - Khởi tạo, cấu hình tham số chỉ mục Vector (ChromaDB/FAISS).	Không gian vector đa nguồn được ánh xạ thành công.

	- Tích hợp đồng bộ truy xuất BM25 và Vector Search.	
Tuần 5	**Tích hợp cơ chế tái xếp hạng (Re-ranking):** - Triển khai kiểm thử hồi quy Cross-Encoder (Cohere/BGE) để chuẩn hóa trật tự. - Đo lường và lập báo cáo biên độ gia tăng chỉ số (Recall/Precision).	Phân hệ truy xuất (Retriever Module) hoàn thiện theo thiết kế.
Tuần 6	**Phát triển Hệ thống đại lý đa chức năng (Agentic RAG):** - Thiết lập System Prompts khắt khe. - Tích hợp các Custom Tools vào bộ khung suy luận ReAct Agent.	Phân hệ kiến tạo và suy luận (Generator & Reasoning Agent) hoàn thiện.
Tuần 7	**Tích hợp Hệ thống và xây dựng giao diện (UI):**	Phiên bản Sản phẩm Khả thi Tối thiểu (MVP) vận hành ổn định.

	- Biên dịch giao diện thông qua Streamlit. - Tích hợp Quản trị Bộ nhớ Hội thoại. - Triển khai Streaming phản hồi.	
Tuần 8	**Kiểm định Chất lượng định lượng:** - Tự động hóa quy trình đánh giá ứng dụng bộ khung RAGAS. - Gỡ lỗi vi mô, tối ưu hóa độ trễ, hoàn tất hồ sơ nghiệm thu kỹ thuật.	Phiên bản hệ thống Production-ready kèm báo cáo dự án .

Danh mục Tài liệu tham khảo

[1] S. Es, J. James, L. Espinosa-Anke, và S. Schockaert, "RAGAS: Automated Evaluation of Retrieval Augmented Generation", *arXiv preprint arXiv:2309.15217*, 2023.

[2] Y. Gao et al., "Retrieval-augmented generation for large language models: A survey", *arXiv preprint arXiv:2312.10997*, 2023.

[3] Z. Ji et al., "Survey of hallucination in natural language generation", *ACM Computing Surveys*, vol. 55, no. 12, tr. 1-38, 2023.

[4] J. Johnson, M. Douze, và H. Jégou, "Billion-scale similarity search with GPUs", *IEEE*

Transactions on Big Data, vol. 7, no. 3, tr. 535-547, 2019.

[5] P. Lewis et al., "Retrieval-augmented generation for knowledge-intensive NLP tasks", *Advances in Neural Information Processing Systems*, vol. 33, tr. 9459-9474, 2020.

[6] R. Nogueira và K. Cho, "Passage Re-ranking with BERT", *arXiv preprint arXiv:1901.04085*, 2019.

[7] S. Robertson, H. Zaragoza, và M. Taylor, "The probabilistic relevance framework: BM25 and beyond", *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, tr. 333-389, 2009.

[8] S. Yao et al., "ReAct: Synergizing reasoning and acting in language models", *arXiv preprint arXiv:2210.03629*, 2022.